MLflow en Databricks

Ejercicio 5 | Pipeline de scikit-learn con seguimiento reproducible

Objetivo

MLflow conecta el desarrollo de modelos con su seguimiento y operación. En Databricks, los runs se registran en un tracking server administrado por el workspace. Este ejercicio adapta un clasificador de Wine con un pipeline de scikit-learn y usa Experiments y MLflow Models.

Usos en proyectos de Machine Learning

Necesidad	Aporte de MLflow y Databricks
Trazabilidad y comparación	Experiments agrupa runs y registra parámetros, métricas, etiquetas, código y artefactos para comparar alternativas.
Reproducibilidad	MLflow Models empaqueta el modelo, la firma de entrada/salida y ejemplos para reutilizarlo con el mismo preprocesamiento.
Features compartidas	Databricks Feature Store permite descubrir y gobernar features, mantener linaje y reutilizar cálculos entre entrenamiento e inferencia. Requiere Unity Catalog en la experiencia actual.
Versionado y despliegue	Model Registry en Unity Catalog centraliza permisos, versiones y linaje; Model Serving publica modelos como endpoints.
Operación	Las herramientas de serving ayudan a observar salud, latencia y solicitudes/respuestas para depurar y monitorear modelos desplegados.

Funcionalidades usadas en esta entrega

Experiments: cada ejecución registra hiperparámetros, accuracy, F1 ponderado y etiquetas. **MLflow Models:** se guarda el pipeline completo (StandardScaler y RandomForestClassifier) con una firma y un ejemplo de entrada. Variar los hiperparámetros y volver a ejecutar crea runs que se pueden comparar.

Alcance de la demo: registra un MLflow Model asociado al run; no crea una versión en Model Registry ni una tabla de Feature Store. Esas funciones se describen como capacidades de la plataforma, pero no se activan porque necesitan catálogo, recursos y permisos del workspace.

Relación con CRISP-DM

CRISP-DM tiene seis fases. MLflow apoya varias con trazabilidad, modelos y servicios de Databricks, pero no reemplaza la comprensión del negocio ni el criterio del equipo.

Fase	Cómo puede apoyar MLflow/Databricks	En este ejercicio
Comprensión del negocio	Puede guardar objetivos, etiquetas y resultados como metadatos; no define por sí solo el problema ni los criterios de negocio.	No cubierta por el código.
Comprensión de datos	Puede registrar datasets, código y artefactos para conservar contexto; el análisis exploratorio sigue siendo tarea del equipo.	Usa Wine incluido en scikit-learn; no hace EDA.
Preparación de datos	Pipelines mantienen el preprocesamiento junto al modelo. Feature Store ayuda a compartir features y reducir diferencias entre entrenamiento e inferencia.	StandardScaler está dentro del pipeline; no usa Feature Store.
Modelado	Experiments registra parámetros y runs; MLflow Models empaqueta modelos de scikit-learn y otros frameworks.	Cubierta: Random Forest y modelo registrado en el run.
Evaluación	Métricas de cada run permiten comparar resultados y elegir una alternativa con evidencia.	Cubierta: accuracy y F1 ponderado. La comparación mejora al ejecutar varias configuraciones.
Despliegue	Model Registry gestiona versiones y permisos; Model Serving publica endpoints. Databricks ofrece herramientas de monitoreo para endpoints.	No desplegado: el modelo solo se registra en el run.

Pipeline implementado

Dataset Wine integrado en scikit-learn; partición 75/25 con estratificación y semilla 42; StandardScaler seguido de RandomForestClassifier (150 árboles, profundidad máxima 5); métricas accuracy y F1 ponderado. El mismo flujo existe en notebook y en archivo Python.

El notebook usa el experimento asociado a Databricks. El archivo Python usa tracking administrado cuando se ejecuta en Databricks Runtime; en una computadora local mantiene SQLite.

Ejecución y entregables

Pasos para ejecutar en Databricks

1. Importa el archivo IPYNB en una carpeta de tu workspace (Workspace > Import).
2. Adjunta el notebook a un Databricks Runtime ML compatible con MLflow 3 o superior.
3. Ejecuta Run all. El dataset viene incluido y no requiere almacenamiento, tokens ni archivos externos.
4. Revisa los runs y el modelo desde Experiments.

Enlaces

Repositorio GitHub - rama ejercicio_5

Notebook ejecutado en el workspace de Databricks

El notebook se ejecutó en Databricks y registró un run de MLflow. La captura de evidencia de la página siguiente muestra el run y las métricas.

Referencias

MLflow en Databricks

Tracking y experimentos

Databricks Feature Store

Model Registry en Unity Catalog

Monitoreo de Model Serving

Fases CRISP-DM (IBM)

API de MLflow para scikit-learn

Evidencia de ejecución en Databricks

La ejecución registró un run en Experiments con accuracy de 1.0 y F1 ponderado de 1.0. La tabla también muestra los parámetros del Random Forest.

